PESQUISA NACIONAL POR AMOSTRA DE DOMICÍLIOS CONTÍNUA (PNADC)

Dia 2 - R e manipulação dos dados da PNADC

Thiago Cordeiro Almeida
Doutorando, Centre d'Estudis Demogràfics (CED, Espanha)
Pesquisador Assistente (Cebrap)

November 11, 2026



ANTES DE COMEÇAR...



lista de presença!

ANTES DE COMEÇAR (2)...

- Dúvidas gerais sobre a aula anterior?
- Exercício da aula anterior: dúvidas, comentários, considerações?



ESTRUTURA DA AULA

Tópicos que vamos cobrir hoje são:

- Ciclos de análise de dados (e pesquisa)
- (Breve) Introdução ao R e RStudio
- Trabalhando com dados de pesquisa amostral complexa
- PNADC no R



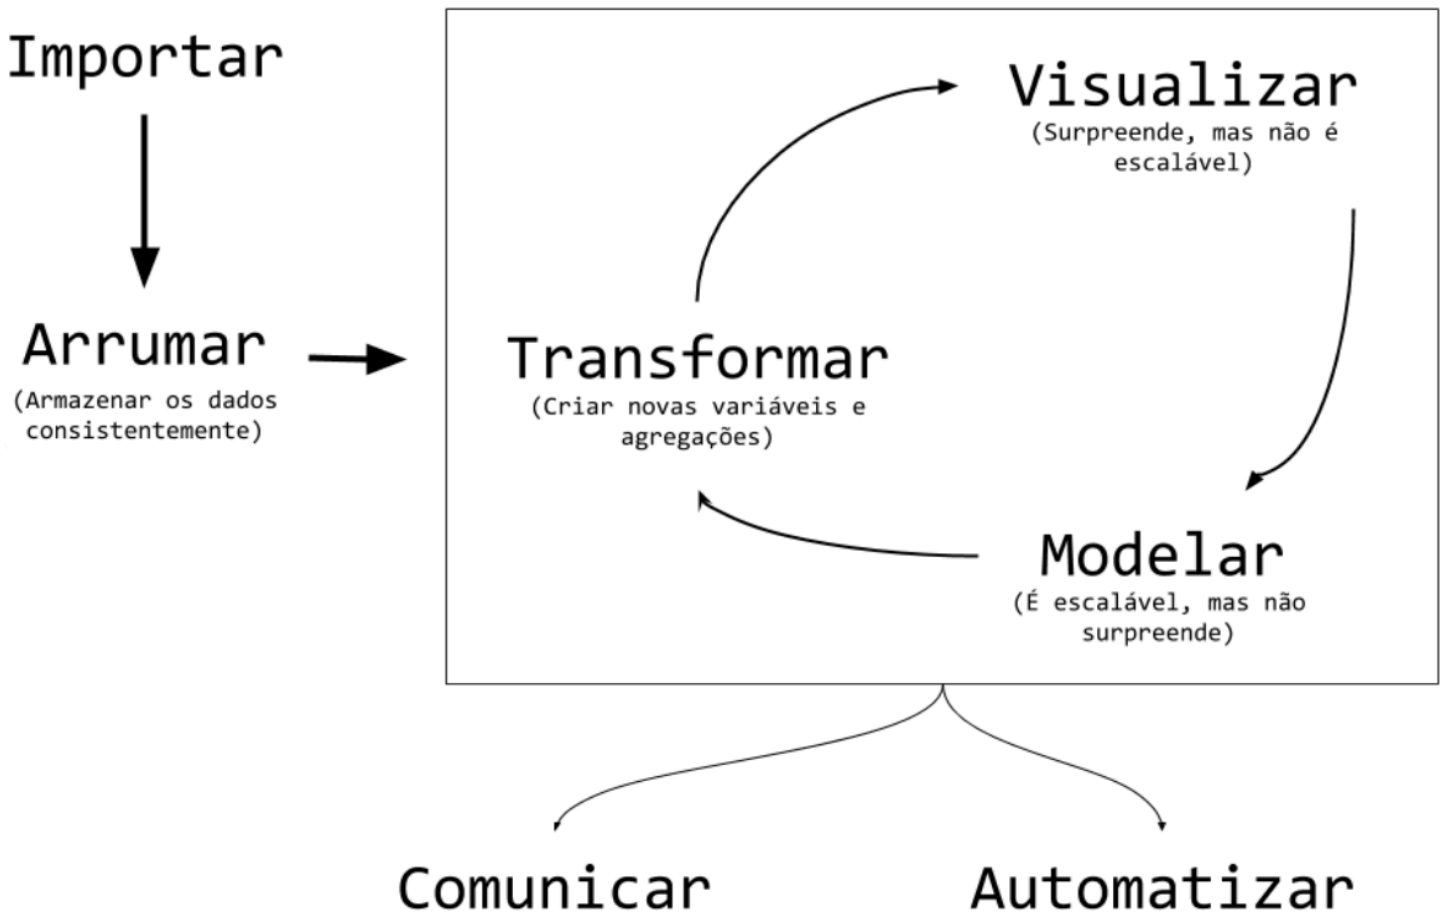
CICLOS DE ANÁLISE DE DADOS

Análise de dados, pesquisa e R



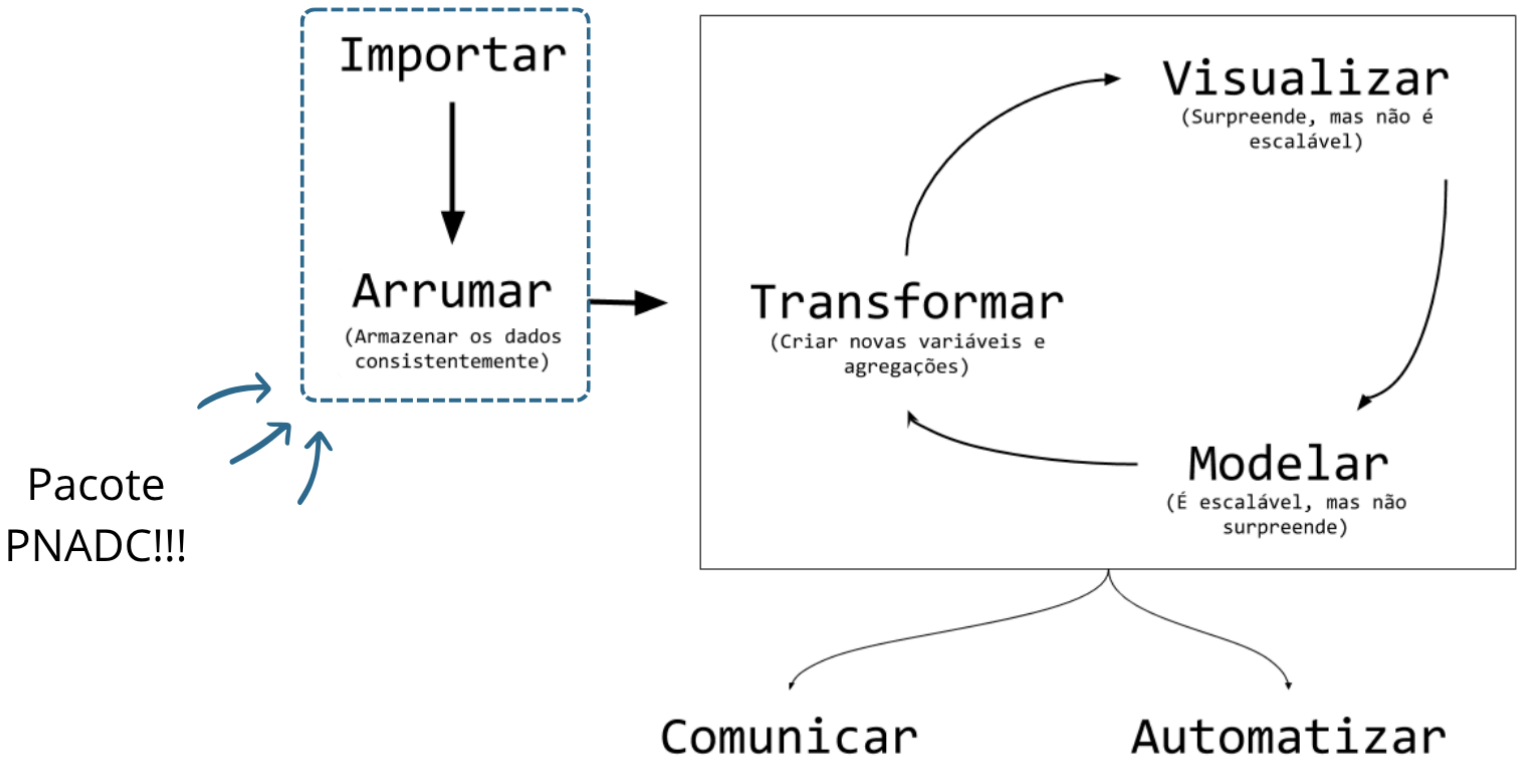
ANÁLISE DE DADOS, PESQUISA E R

Fluxo de análise de dados[1] que, geralmente, seguimos:



ANÁLISE DE DADOS, PESQUISA E R

Fluxo de análise de dados[1] que, geralmente, seguimos:



INTRODUÇÃO AO R E RSTUDIO

Os softwares



R

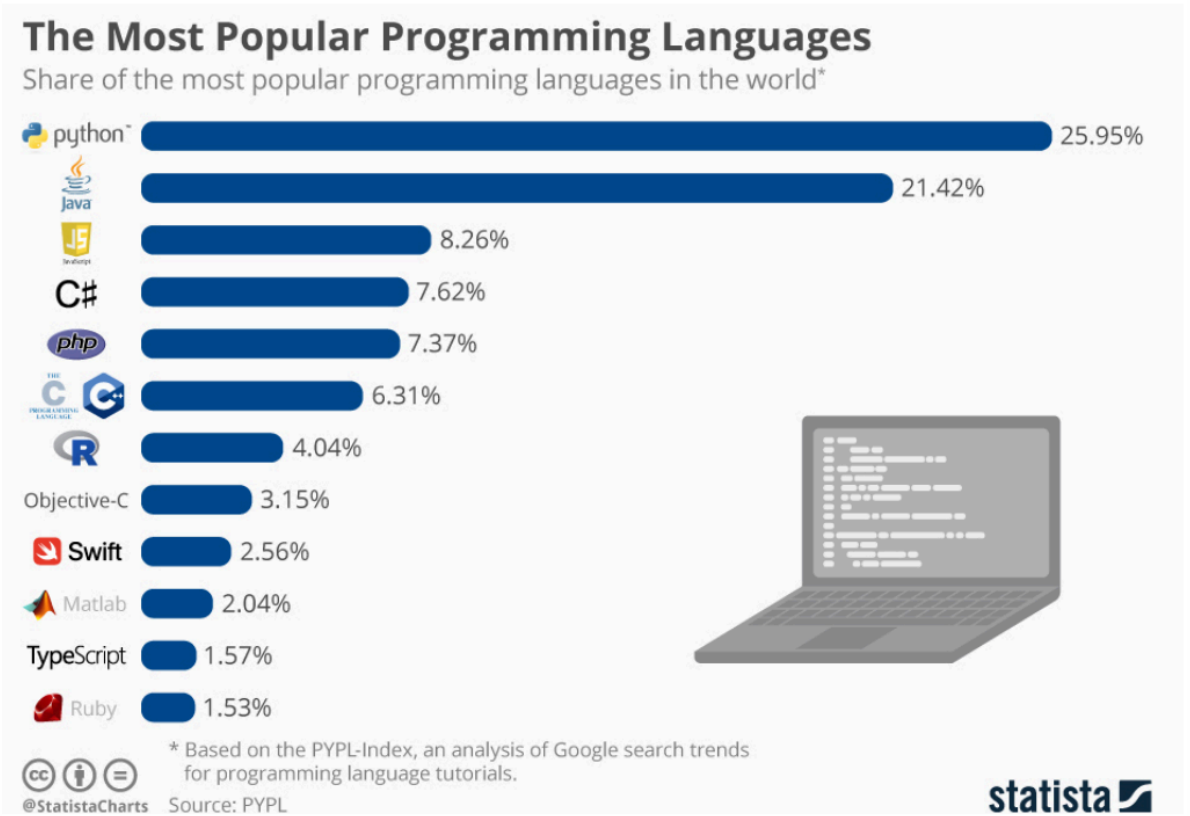
Sobre a linguagem R



- Criada em 1995
- É uma linguagem de programação open source muldialmente conhecida e utilizada
- Por ser mundialmente conhecida e utilizada... há uma grande comunidade de usuários que contribuem para a sua melhoria
- Principais funções do R
  - Manipulação de dados
  - Ferramentas estatísticas
  - Produção de gráficos de alta qualidade
  - Georreferenciamento

Motivações para aprender (e se aprofundar):

- **Independência** de outros programas pagos
- Imensa potencialidade das **analises** possíveis de serem feitas
- Capacidade de trabalhar com análises **QUANTI e QUALI** em um único software
- Capacidade de desenvolver/implementar seus **próprios algorítmos**
- Elevadíssima **empregabilidade**



RSTUDIO

Sobre a IDE



- É um IDE (Integrated Development Environment) criada para o R;
- É um ambiente mais amigável de se trabalhar do que no R;
- Facilita e potencializa a programação em uma determinada linguagem
- RStudio não é a única IDE do R, há outras que podem ser vistas e usadas por aí:
  - VSCODE
  - PyCharm
  - Eclipse
  - ...

INTRODUÇÃO AO R E RSTUDIO

Conceitos básicos para a PNADC



CONCEITOS BÁSICOS PARA A PNADC

Objetos de armazenamento no R

- **Objeto:** é um "nome" que damos para guardar algum valor ou atributo.
  - Usamos `<-` ou `=` para atribuir algum valor a um nome.
- **Vetor:** é um conjunto de valores de *mesma classe* atribuídos a um objeto.
  - Usamos, em geral, a função `c()` para concatenar os valores no objeto.
- **Dataframes:** são objetos que guardam nossos dados. Possuem linhas e colunas.
  - Todos os seus elementos (colunas) têm que ter o mesmo número de linhas
  - Todos os seus elementos (colunas) precisam ser nomeados.
  - Têm duas dimensões.
- **Listas:** é uma generalização dos datataframes e vetores. Permite agregar diferentes classes de objetos dentro dela.
  - Todo dataframe é uma lista
  - Todo vetor é uma lista.



CONCEITOS BÁSICOS PARA A PNADC

Outros aspectos importantes

- **Cada coluna de um dataframe é tratada como uma variável**
  - Cada coluna/variável deve, assim, ter somente uma classe/tipo.
- **É possível armazenar uma variável em um vetor**
  - Este vetor, por sua vez, pode ser inserido em um dataframe posteriormente.
- **Survey Design:** no R, é um tipo de objeto.
  - É tratado assim quando é declarado como tal.
  - Deve ser fruto de uma pesquisa amostral cujo o seu uso exige que se estabeleça ponderações previamente determinadas.
  - Para tanto, é importante que se conheça a documentação da pesquisa a ser utilizada



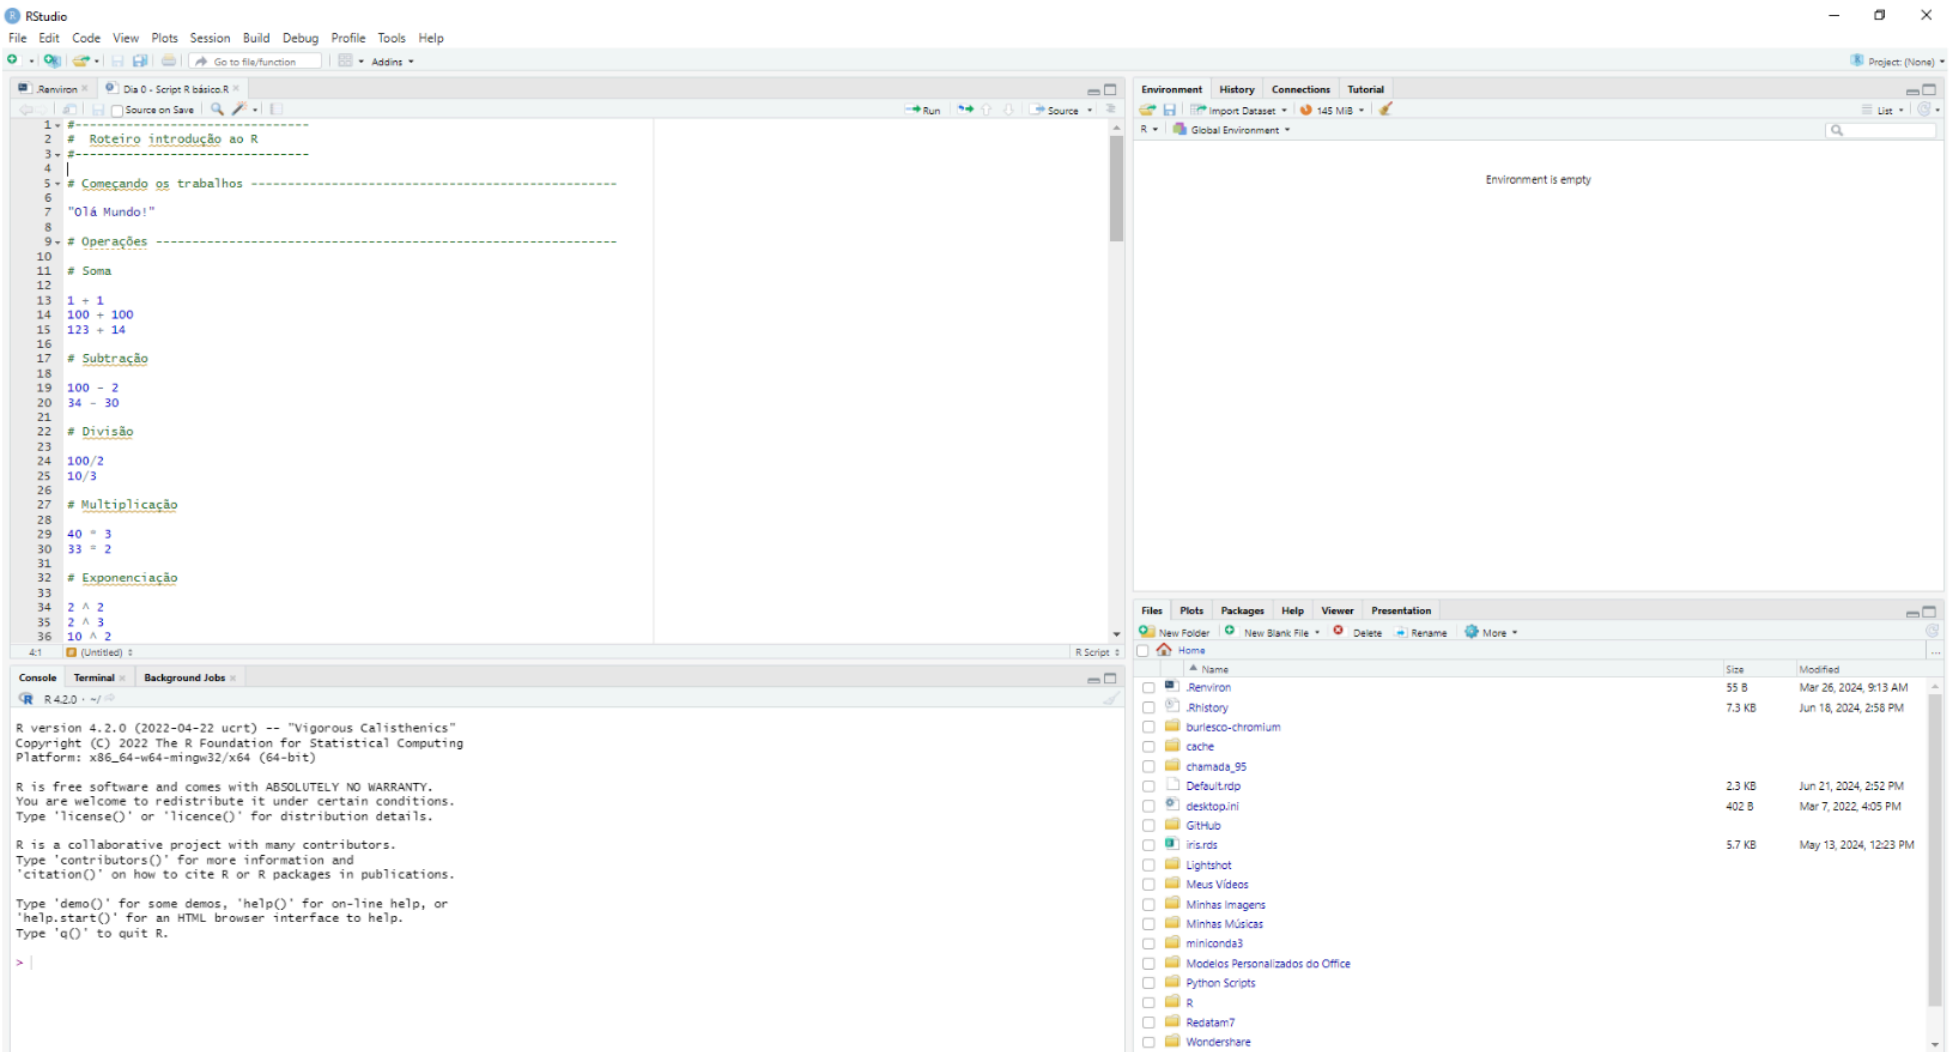
CONCEITOS BÁSICOS PARA A PNADC

O R é uma linguagem de programação muito próximo da forma “falada”.

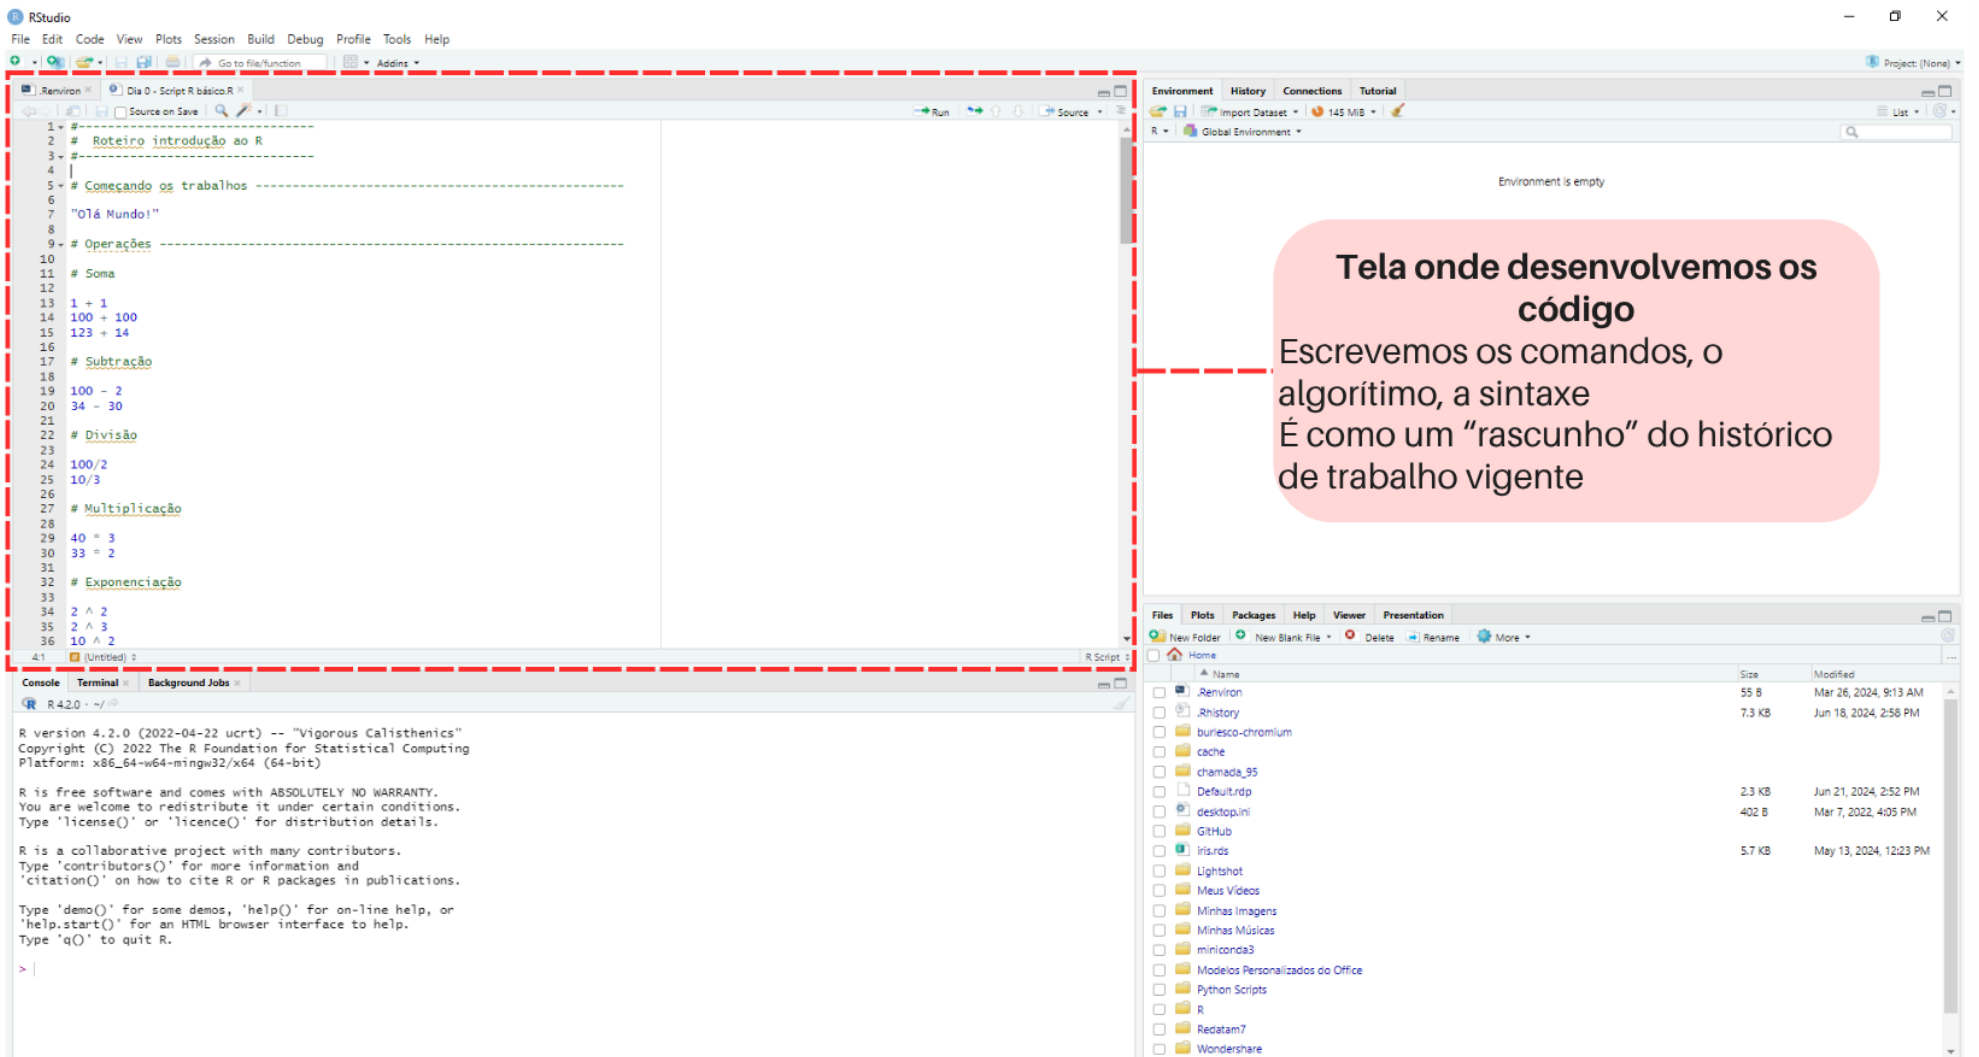
- **Comandos**
  - Nós usamos “verbos” (comandos/funções) para indicar as ações que queremos conduzir no R.
- **Comandos básicos do R (R base)**
  - São comandos que estão na raiz do programa, eles vêm junto com a sua instalação.
- **Pacotes**
  - São conjuntos de comandos (funções) que baixamos em nossa máquina e executamos para obter processamentos específicos.
  - Um pacote pode contar uma série de funções/comandos.



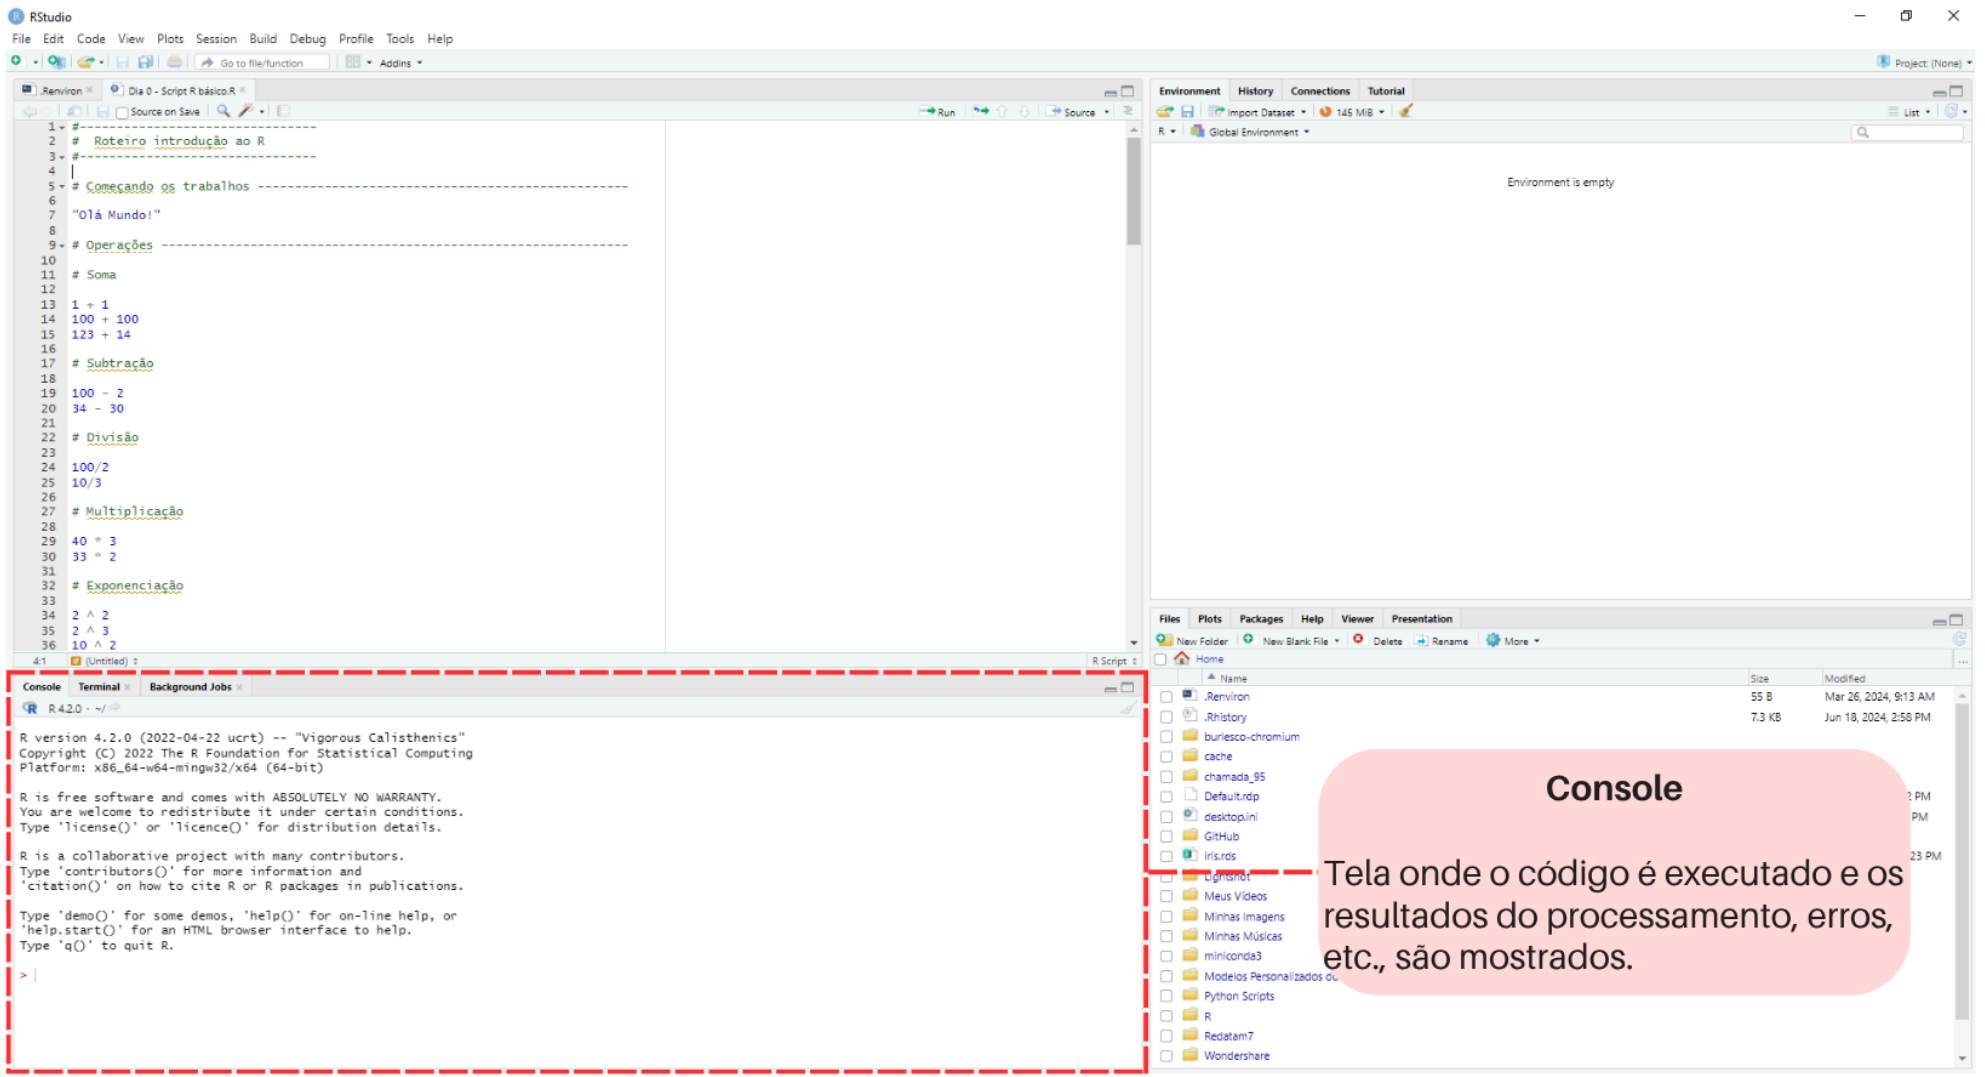
VISÃO GERAL DE COMO FUNCIONA O RSTUDIO



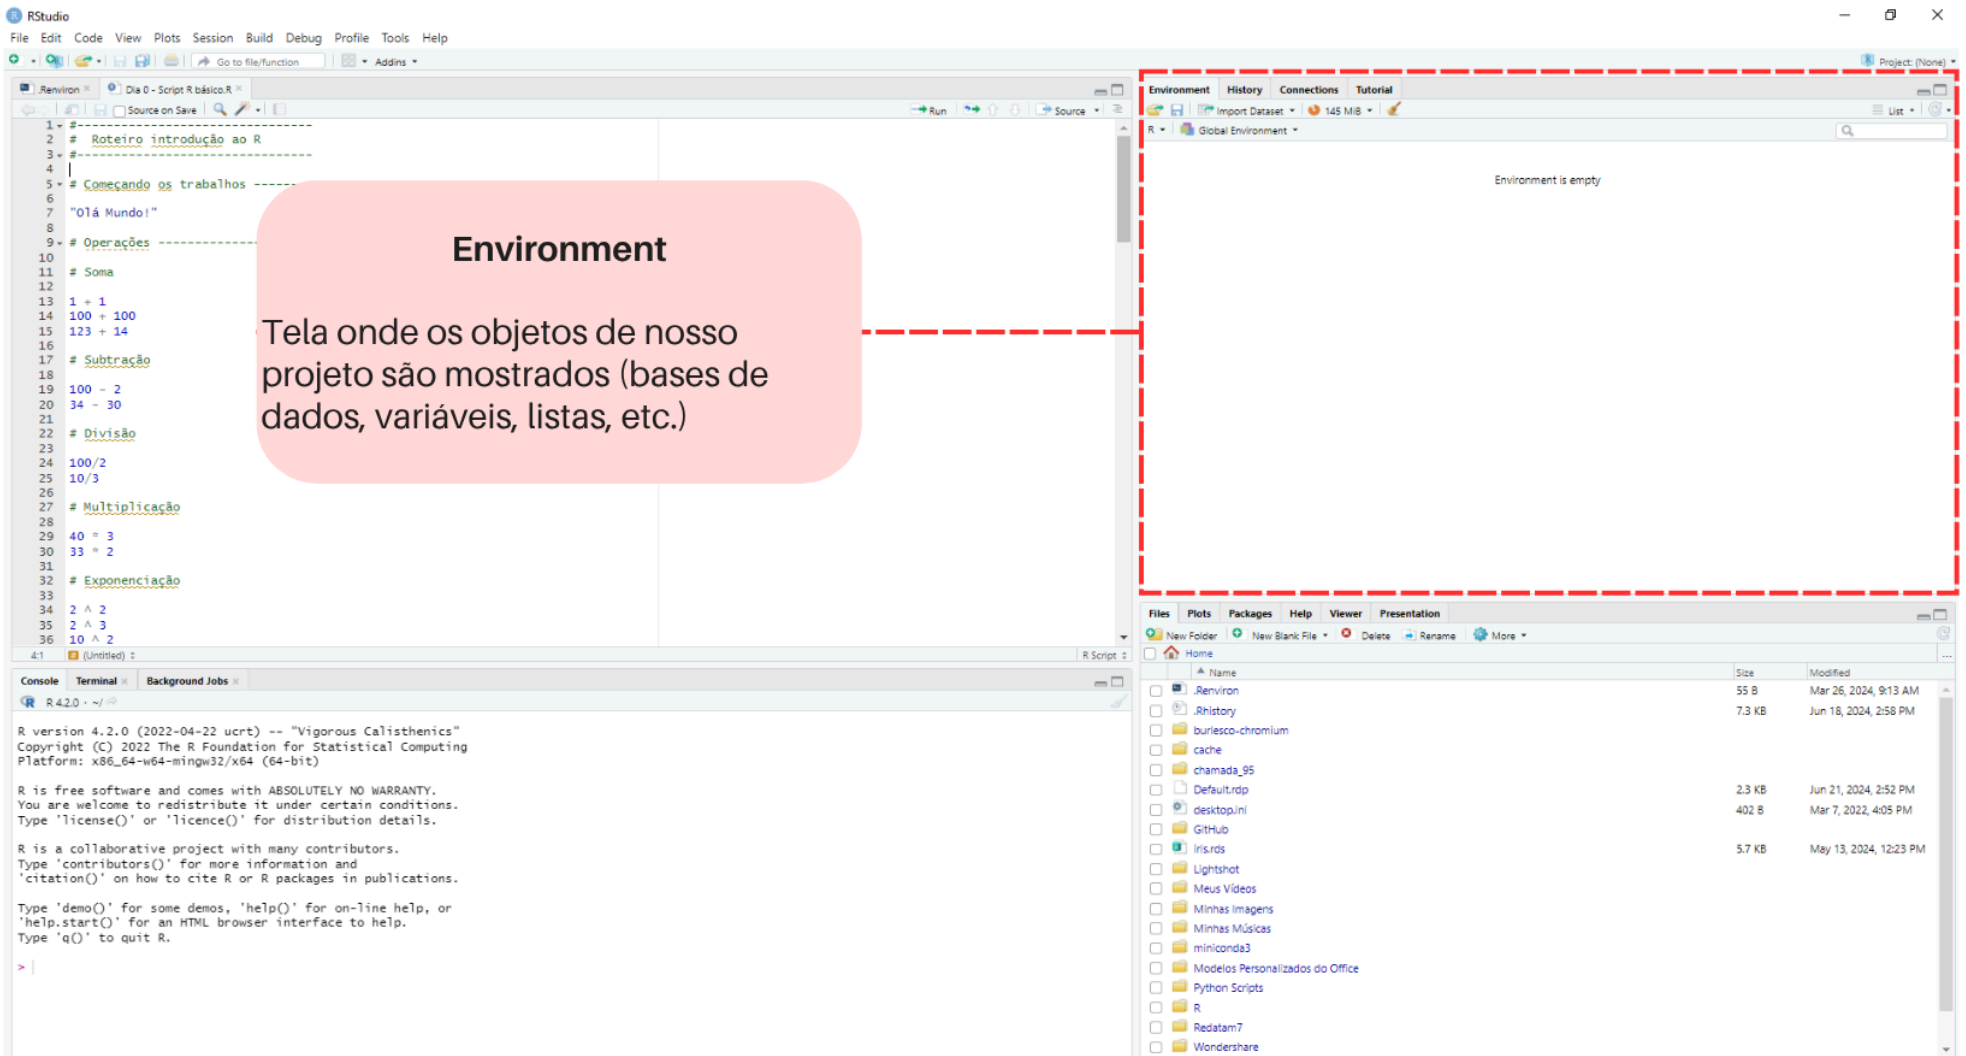
VISÃO GERAL DE COMO FUNCIONA O RSTUDIO



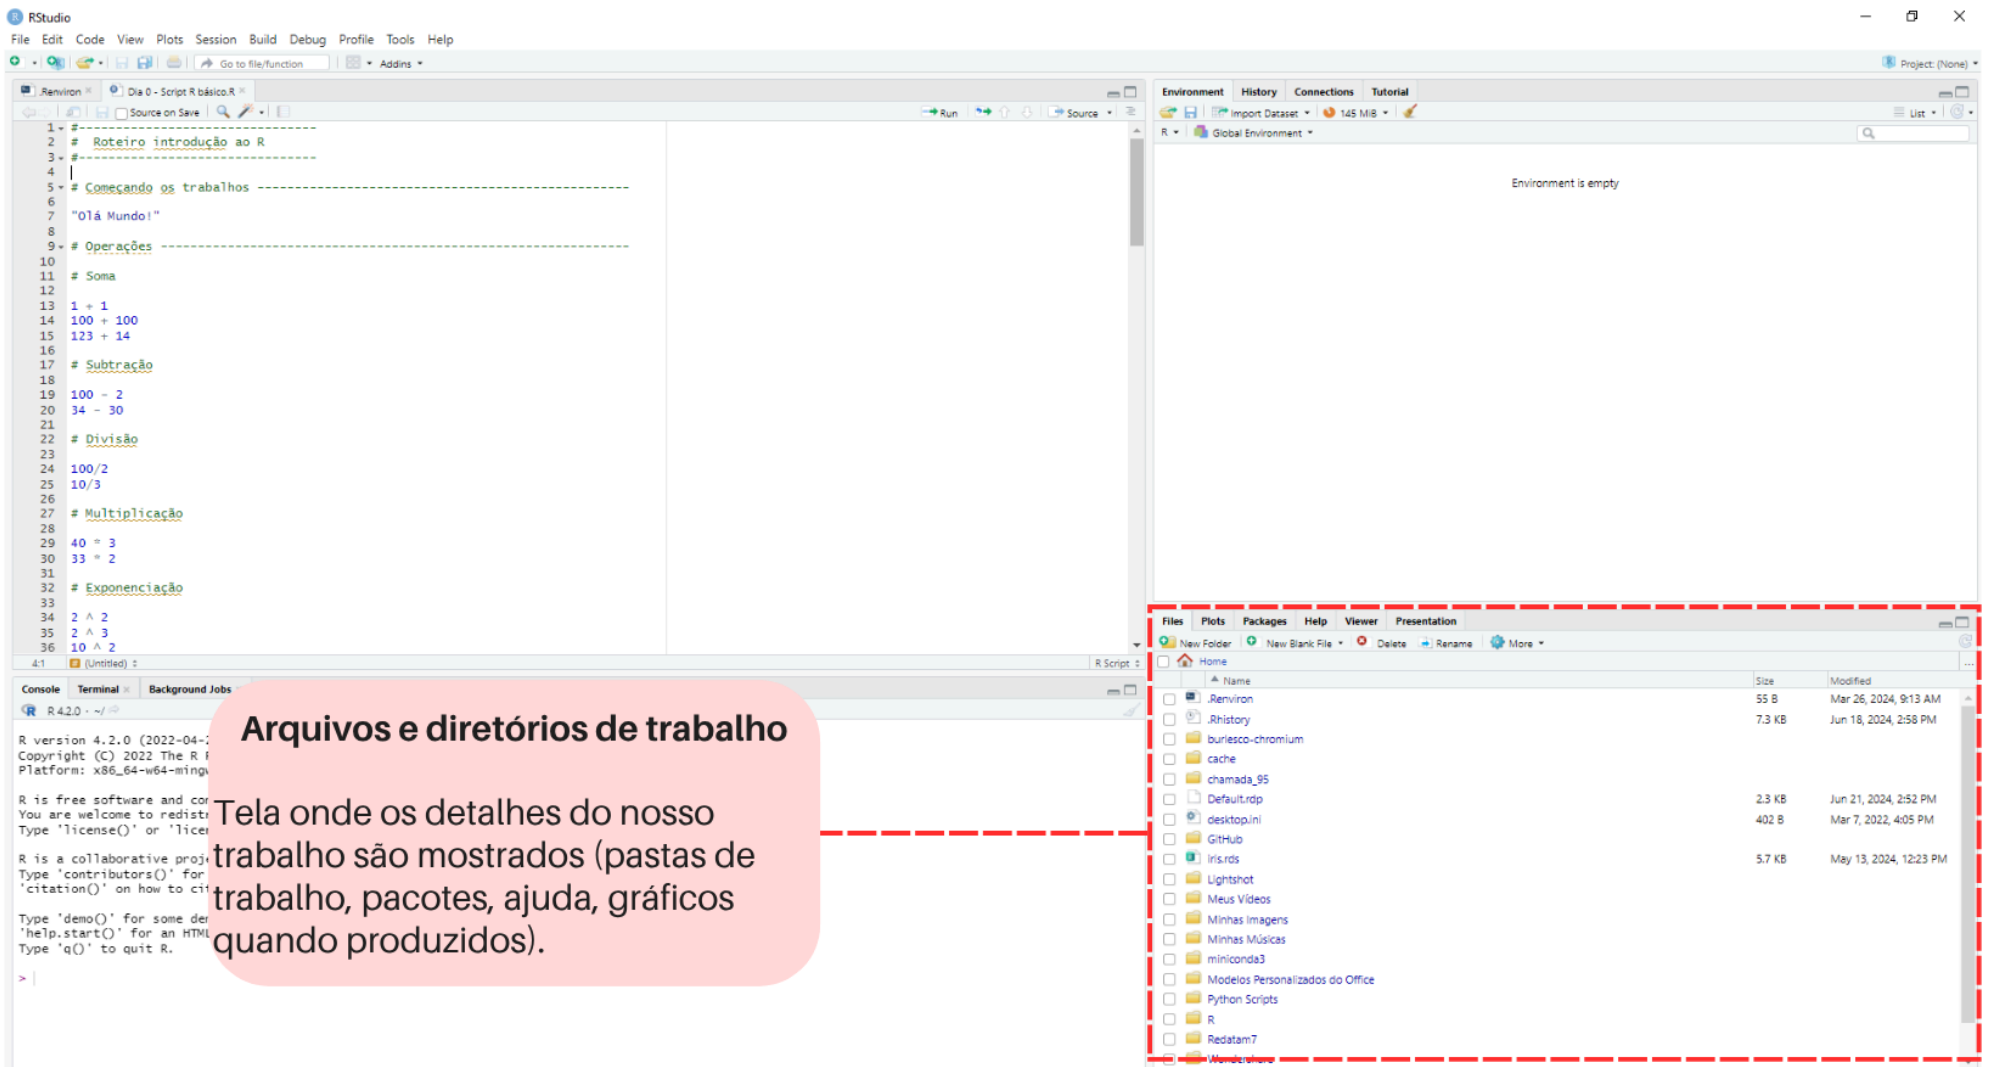
VISÃO GERAL DE COMO FUNCIONA O RSTUDIO



VISÃO GERAL DE COMO FUNCIONA O RSTUDIO



VISÃO GERAL DE COMO FUNCIONA O RSTUDIO



BUSCANDO AJUDA

A maior arte do saber programar é saber onde procurar por resoluções dos problemas!!!



BUSCANDO AJUDA

Onde buscar?

GOOGLE

- Por haver uma grande comunidade de usuários do R, há uma grande produção de conteúdos.
- O Google é uma ferramenta de busca capaz de selecionar alguns conteúdos associados à sua busca[1].

STACK OVERFLOW

- É um site de pergunta e resposta muito utilizado em outros países. É fortemente alimentado por usuários de linguagem de programação (inclusive R!!!)[2].



BUSCANDO AJUDA

Onde buscar?

IA'S

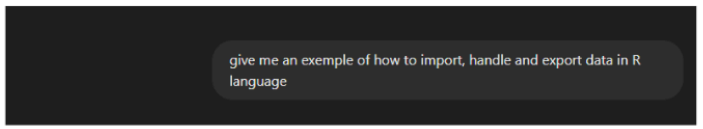
- Enquanto uma ferramenta de IA, auxilia na compreensão de problemas de programação ou para oferecer alternativas não imaginadas.
- Usemos com cautela...

BUSCANDO AJUDA

Onde buscar?

IA'S

- Enquanto uma ferramenta de IA, auxilia na compreensão de problemas de programação ou para oferecer alternativas não imaginadas.
- Usemos com cautela...



Resultado

Step 1: Importing Data

First, let's import a CSV file into R. We'll use the `read.csv` function to read the data.

r Copy code

```r
# Importing data
data <- read.csv("path/to/your/file.csv")

# Viewing the first few rows of the data
head(data)
```

Step 2: Handling Data

Now that we have the data imported, let's perform some basic data handling operations. We'll check for missing values, summary statistics, and make some modifications to the data.

r Copy code

```r
# Check for missing values
sum(is.na(data))

# Summary statistics
summary(data)

# Rename a column
names(data)[names(data) == "old_column_name"] <- "new_column_name"

# Create a new column
data$new_column <- data$existing_column * 2

# Filter data (e.g., rows where a specific column is greater than a value)
filtered_data <- subset(data, specific_column > value)

# Sort data
sorted_data <- data[order(data$specific_column), ]

# Aggregating data (e.g., mean of a column grouped by another column)
aggregated_data <- aggregate(data$numeric_column, by=list(data$group_column), FUN=mean)
names(aggregated_data) <- c("Group", "MeanValue")
```

Step 3: Exporting Data

Finally, let's export the modified data back to a CSV file. We'll use the `write.csv` function for this.

r Copy code

```r
# Exporting data to a new CSV file
write.csv(data, "path/to/your/output_file.csv", row.names = FALSE)
```

EXERCÍCIO!



Usando a planilha “Trabalhadores”, disponível na pasta “arquivos complementares > prática”, calcule:

1. Qual a média salarial de cada trabalhador (média entre salário anterior e o salário atual)?
2. Faça uma coluna dizendo se o salário atual é “MAIOR” ou “MENOR” que o salário anterior.
3. Qual a média de idade de todos os trabalhadores?



PAUSA!



TRABALHANDO COM DADOS DE PESQUISA AMOSTRAL COMPLEXA

Pesos amostrais



PESO AMOSTRAL

É uma variável (ou um conjunto delas) que ajusta, pondera e expande os resultados de uma determinada amostra para a população.

Algumas observações sobre os pesos:

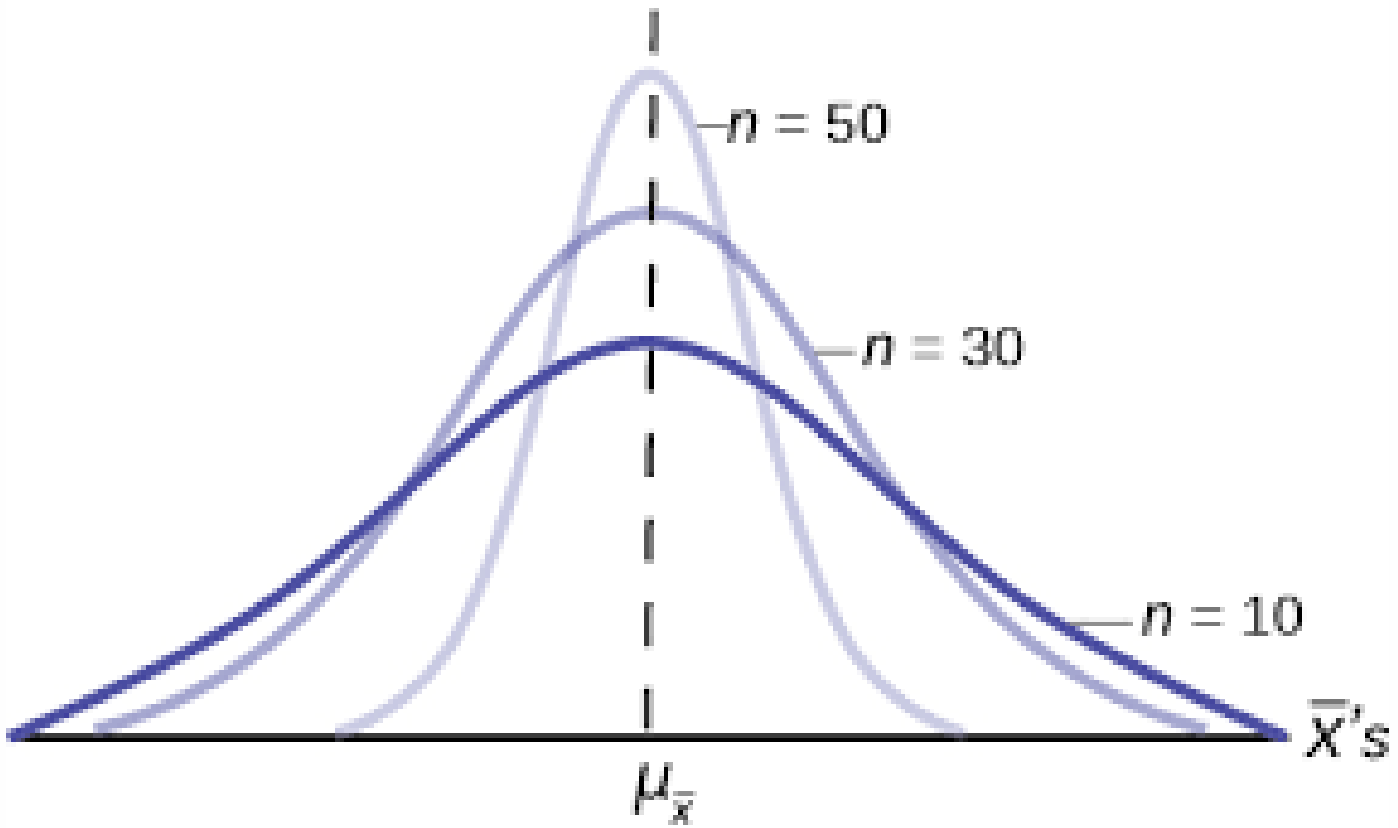
- Garantem a representatividade dos dados que estamos trabalhando para a população em análise.
- Realizar análises com a PNADC sem declarar/aplicar seus pesos incorre em um grave erro e pode gerar estimativas viesadas[1].
- Há pacotes que otimizam nossa análise por não precisarmos de declarar os pesos ou precisarmos de declarar somente uma vez:
  - `{PNADcIBGE}`
  - `{survey}`



PESOS AMOSTRAIS

Os pesos nos dizem sobre:

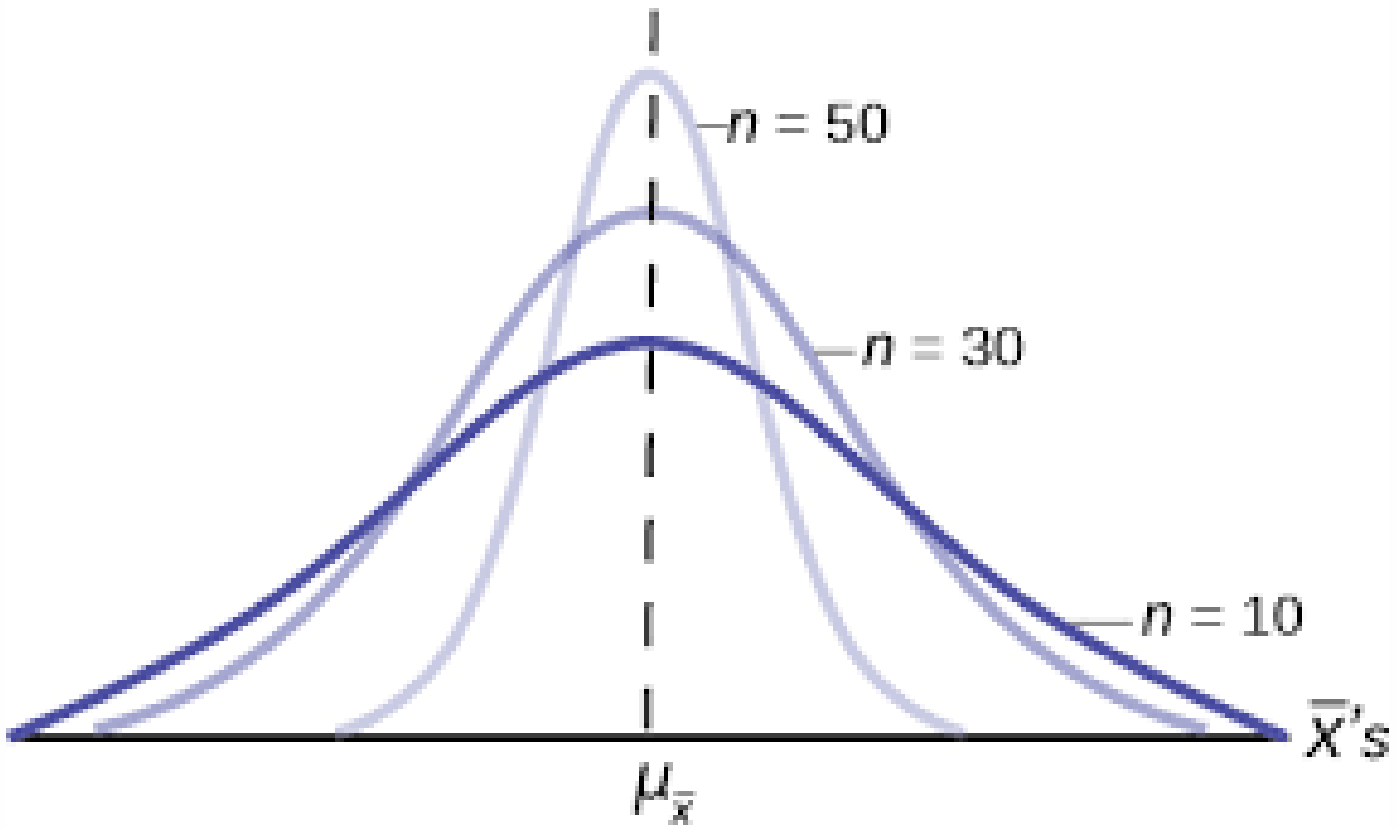
- Precisão da estimativa
- Incerteza da estimativa



PESOS AMOSTRAIS

Quando se aplica os pesos:

- Estamos ponderando cada observação da nossa **amostra** pela sua importância relativa na população.
- **Amostra PNADC:** Domicílios em que informações foram coletadas na pesquisa.
- **População PNADC:** Recenseamento brasileiro de domicílios.



PESOS AMOSTRAIS

Atenção!

- A PNADC é uma pesquisa que tem como unidade de amostragem os **domicílios**
- Seus pesos são os mesmos para todos os indivíduos de um determinado domicílio.
- Quando expandidos, vão acompanhar determinadas características da população:
  - Para Brasil e UFs: total, idade e sexo
  - Para demais níveis geográficos: total



NÍVEL DO DOMICÍLIO OU DOS INDIVÍDUOS?

Nossa unidade de coleta é cada **domicílio**, mas coletamos dados também das **pessoas** (moradores).

Peso de cada domicílio e pessoa:

- **Domicílio:** recebe um peso relativo ao extrato ao qual ele se encontra.
  - Compreender o modo como a Amostra Mestre é construída é importante por isso!
- **Pessoa:** todas de um domicílio recebem o mesmo peso[1].

Quando expandimos a amostra, temos (i) representatividade do número de domicílios para a respectiva unidade; e (ii) representativa da população para a mesma unidade.



NÍVEL DO DOMICÍLIO OU DOS INDIVÍDUOS?

Chave de identificação de cada pessoa e domicílio:

- **Domicílio**:

$$UPA + V1008 + V1014$$

- **Pessoa**:

$$UPA + V1008 + V1014 + V2003 = Domicílio + V2003$$

Em que:

- UPA: Unidade Primária de Amostragem
- $V1008$: Número de Seleção de Domicílios
- $V1014$: Número do painel
- $V2003$: Número de ordem da pessoa no domicílio



TRABALHANDO COM DADOS DE PESQUISA AMOSTRAL COMPLEXA

Medidas



MEDIDAS DE TENDÊNCIA CENTRAL

Sinaliza para tendências gerais (médias) de determinada distribuição.

As medidas de tendência central são bastante utilizadas para sintetizar/resumir os possíveis/prováveis valores a serem encontrados em uma distribuição.

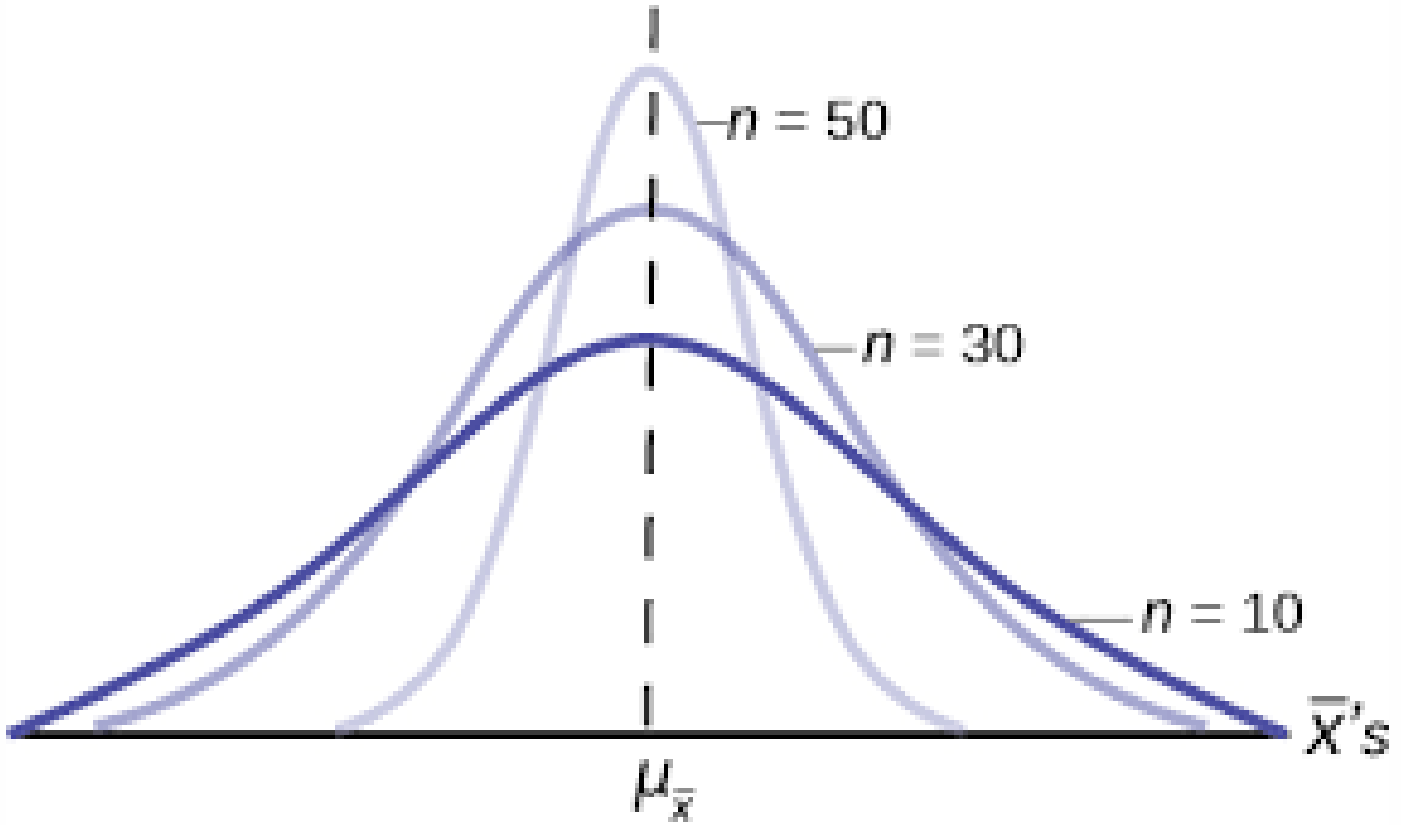
- **Média:** é a principal das medidas de tendência central
- Ela nos diz que, a depender da distribuição de nossos valores, em geral, temos grande chance de obtermos, aleatoriamente, um valor que se aproxime do **valor médio**.
- Por termos uma amostra aleatória e representativa para as unidades geográficas que estudamos, podemos dizer que os valores médios de nossos indicadores representam aqueles valores mais esperados de serem encontrados para a unidade de análise.
- **Uma estimativa é também um valor médio (!)**



MEDIDAS

Alguns tipos de medidas:

- Números absolutos
- Proporção
- Razão
- Média/moda/mediana/...



TÉCNICAS DE AVALIAÇÃO DA QUALIDADE DA ESTIMATIVA

Há algumas formas de avaliarmos a qualidade das estimativas através de medidas de variabilidade.



TÉCNICAS DE AVALIAÇÃO DA QUALIDADE DA ESTIMATIVA

Há algumas formas de avaliarmos a qualidade das estimativas através de medidas de variabilidade.

Intervalo de Confiança

- Diz respeito à confiabilidade das estimativas produzidas.
- Os limites dizem qual é a faixa dentro da qual os resultados podem variar, caso o estudo seja repetido N vezes.

Coeficiente de Variação (CV) ou Desvio Padrão Relativo (DPR)[1]

- É um indicador de medida relativa da precisão.
- Calculado como Razão entre erro padrão e a média (valor estimado do indicador).
- Em geral, é multiplicado por 100.

TÉCNICAS DE AVALIAÇÃO DA QUALIDADE DA ESTIMATIVA

Há algumas formas de avaliarmos a qualidade das estimativas através de medidas de variabilidade.

Intervalo de Confiança

- Diz respeito à confiabilidade das estimativas produzidas.
- Os limites dizem qual é a faixa dentro da qual os resultados podem variar, caso o estudo seja repetido N vezes.

Coeficiente de Variação (CV) ou Desvio Padrão Relativo (DPR)[1]

Quadro – Classificação das estimativas quanto à precisão

Indicador	Intervalo do coeficiente de variação - CV (%)	Conceito
Z	Zero	Exata
A	Até 5	Ótima
B	Mais de 5 a15	Boa
C	Mais de 15 a 30	Razoável
D	Mais de 30 a 50	Pouco precisa
E	Mais de 50	Imprecisa

Fonte: IBGE, Diretoria de Pesquisas.

TÉCNICAS DE AVALIAÇÃO DA QUALIDADE DA ESTIMATIVA

Como podemos usar cada uma das medidas?

Intervalo de Confiança

- Quando estamos comparando grupos.
- Em alguns casos é reportado junto com a estimativa: $estimativa\ [CI_baixo; CI_alto]$.
- Quanto mais desagregarmos nossas análises para características da pop. ou recorte geográfico, maior será o IC.

Coeficiente de Variação (CV) ou Desvio Padrão Relativo (DPR)

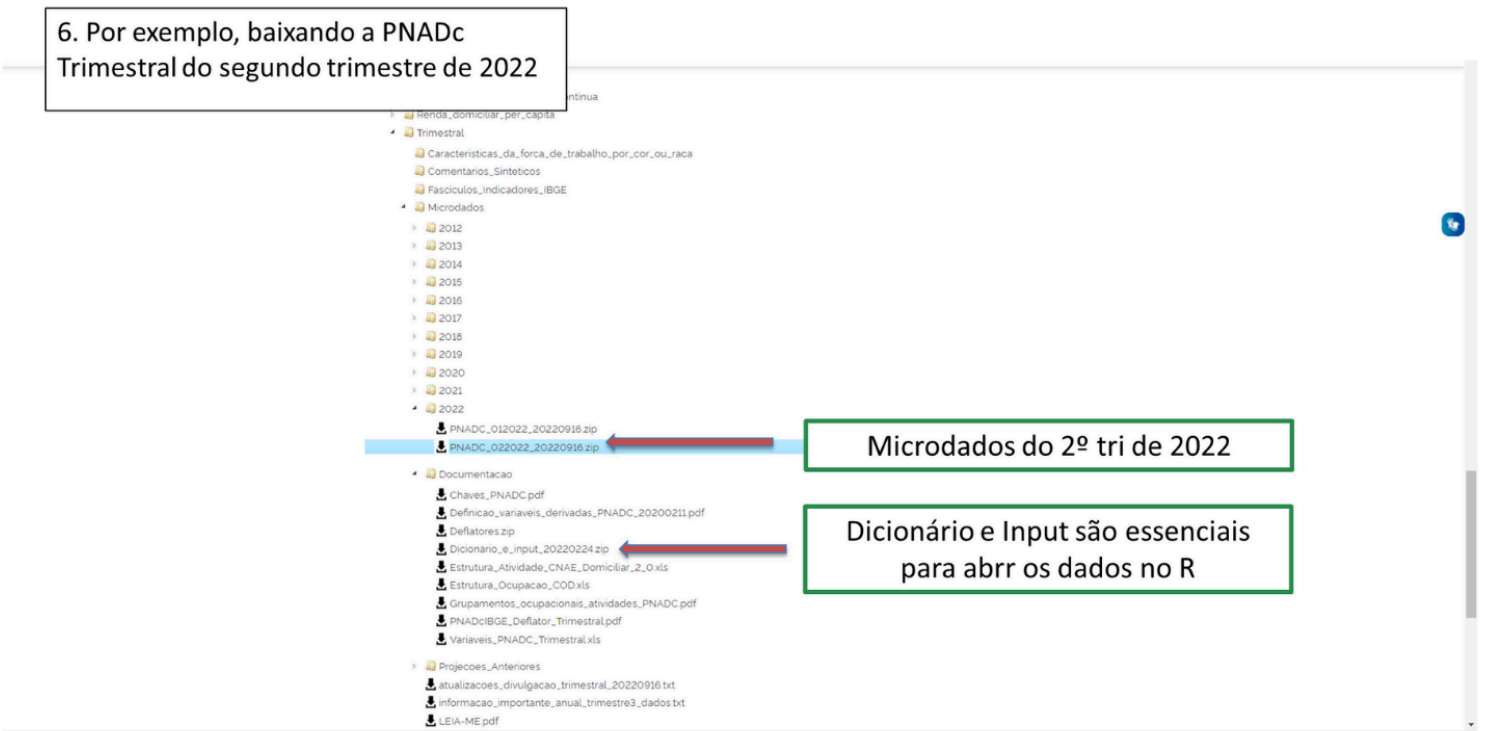
- Para todas as estimativas.
- Nem sempre é reportado, mas é uma boa prática calcular quando se tem as estimativas finalísticas de determinados indicadores.

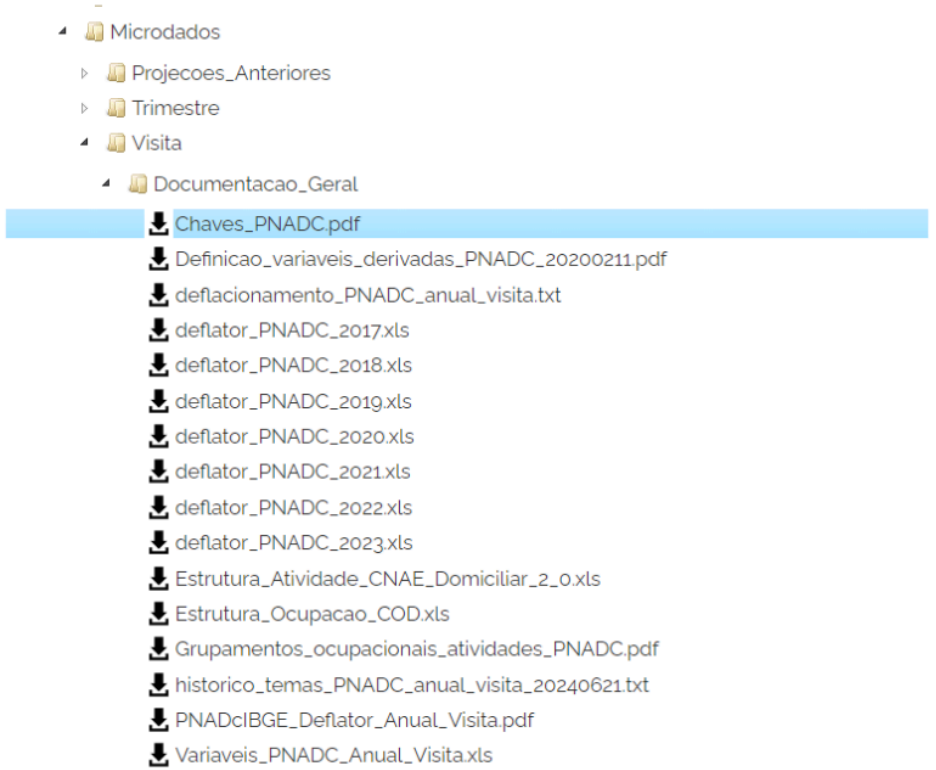
PNADC NO R



COMPLEMENTOS

Na aula anterior, aprendemos como acessar os microdados no site do IBGE...





Alguns materiais complementares (também conhecidos como documentação) são importantes de serem acessados sempre que houver dúvida na pesquisa:

- **Questionário:** onde há a descrição das variáveis existentes
- **Notas Técnicas:** onde se descreve mudanças metodológicas ocorridas ou erros identificados.
- **Metodologia:** onde está descrito estratégias tomadas para criação da pesquisa.
- **Dicionário de variáveis:** é onde se encontra o código da variável, descrição de valores possíveis e tamanho da variável.
- **Inputs:** é um arquivo organizado de modo a facilitar a importação dos dados.

PACOTES PARA ANÁLISE DOS DADOS DA PNADC EM R

Principais pacotes para facilitar a análise e modelagem dos microdados da PNAD Contínua em R:

- `{PNADcIBGE}`: permite baixar e preparar os microdados da PNAD Contínua para análise.
- survey: pacote que permite análise e modelagem de dados provenientes de pesquisas com amostras complexas, em geral.



PACOTES PARA ANÁLISE DOS DADOS DA PNADC EM R

Primeiro, instalamos os pacotes em R[1]...

- PNADcIBGE: `install.packages("PNADcIBGE")`
- survey: `install.packages("survey")`



PACOTES PARA ANÁLISE DOS DADOS DA PNADC EM R

Depois, carregamos os pacotes de interesse[1]...

- PNADcIBGE:

```
1  library(PNADcIBGE)
```

- survey:

```
1  library(survey)
```




FAZENDO DOWNLOAD DOS BANCOS DE DADOS EM R

1. Diretamente no R: É possível baixar diretamente no R, selecionando as variáveis desejadas e já contemplando o plano amostral[1].

Exemplo 1: Baixando o banco do segundo trimestre de 2023

```
1  Pnad_2023_2s <- get_pnadc(year = 2023, quarter = 2, design = TRUE, vars = c("UF","V2007", "VD4009", "VD4019"))
```

Exemplo 2: Microdados anuais concentrados em determinado trimestre (2020, 2° trimestre)

```
1  dadosPNADc_anual_trimestre_2020 <- get_pnadc(year=2020, topic=2)
```




FAZENDO DOWNLOAD DOS BANCOS DE DADOS EM R

2. É possível baixar no site do IBGE e abrir no R: Neste caso, será necessário atribuir o "input" e os labels das variáveis. Para isso, é necessário que o banco de dados, o arquivo de input (.txt) e o dicionário (xls) estejam todos baixados. Todos esses 3 arquivos (banco de dados, input e dicionário) podem ser baixados no site do IBGE.

Exemplo de código para isso: Terceiro trimestre de 2016

```
# 1 - Atribuindo um Working diretory (precisa ser a pasta onde os arquivos que você baixou do site do IBGE estão)
setwd("C:/Users/User/Desktop/Aulas/Cebrap/Práticas em R/")

# 2 - Abrindo o banco do terceiro trimestre de 2016 que baixei no site do IBGE
Pnad_3trim_2016 <- read_pnadc(
  microdata = "PNADC_032016.txt",
  input_txt = "input_PNADC_trimestral.txt"
)

# 3 - Atribuindo os labels ao banco de 2016
Pnad_3trim_2016 <- pnadc_labeller(
  data_pnadc = Pnad_3trim_2016,
  dictionary.file = "dicionario_PNADC_microdados_trimestral.xls"
)

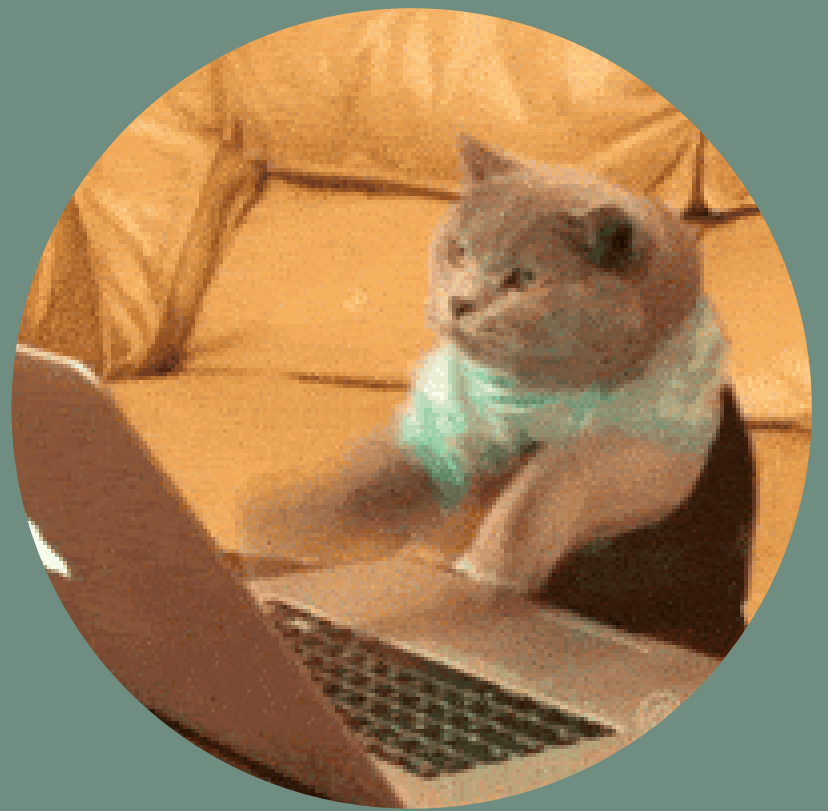
# 4 - Atribuindo o plano amostral ao banco de dados
Pnad_3trim_2016 <- pnadc_design(Pnad_3trim_2016 )
```




EXERCÍCIO!



Abram script `praticas > Dia 2 - Intro Pnad.R`.



ISSO É TUDO PARA HOJE!

Para próxima aula:

1. Exercícios assíncrono
2. Leitura de material para aula de hoje (caso não tenha lido)
3. Leitura de material para a aula seguinte (Ver ementa): validação de estimativas obtidas com a PNADC



ORIENTAÇÕES SOBRE O EXERCÍCIO (1/2)

Baixar a Pnad trimestral do 1º, 2º, 3º e 4º trimestre de 2021.

1. Qual é o número de empregados com carteira assinada em cada um dos trimestres (VD4009)?

- Faça um gráfico de linha no Excel (ou R) do 1º ao 4º trimestre com o retrato dessa variável em cada um dos trimestres.

2. Qual a condição de ocupação na semana de referência para pessoas de 14 anos ou mais de idade em cada um dos 4 trimestres? (VD4002)

- Faça um gráfico de linha no Excel (ou R) do 1º ao 4º trimestre com o retrato dessa variável em cada um dos trimestres.



ORIENTAÇÕES SOBRE O EXERCÍCIO (2/2): DICA...

1. Você precisará criar 4 objetos survey. Ou seja, o comando abaixo precisará ser dado 4 vezes, uma para cada trimestre.

```
NOME_1 <- get_pnadc(year = ANO, quarter = TRIMESTRE, design = TRUE,
vars = c("VAR", "VAR"))
```

```
NOME_2 <- get_pnadc(year = ANO, quarter = TRIMESTRE, design = TRUE,
vars = c("VAR", "VAR"))
```

```
NOME_3 <- get_pnadc(year = ANO, quarter = TRIMESTRE, design = TRUE,
vars = c("VAR", "VAR"))
```

```
NOME_4 <- get_pnadc(year = ANO, quarter = TRIMESTRE, design = TRUE,
vars = c("VAR", "VAR"))
```

2. Além disso, executará o comando `svytotal()` para cada um desses objetos criados;

3. Para cada um deles, vai gerar um Excel/CSV e depois você irá, manualmente, uni-los em um excel à parte.



50 ANOS
CEBRAP

Presidência	Adrian Gurza Lavalle
Diretoria Administrativa	Victor Callil
Diretoria Científica	Arilson Favareto
Coordenação de Seminários	Bianca Tavolari
Coordenação de Cursos	Monise Fernandes Picanço

Curso

Pesquisa Nacional por Amostra de Domicílios Contínua (PNADC)

Ministrante

Thiago Cordeiro Almeida

E-mail: thiagocordalmeida@gmail.com

Github: @thiagocalm